Schemat projektu systemu predykcji toru lotu do zastosowań w telemetrii platform suborbitalnych

Alicja Macutkiewicz, Weronika Marszalik,
Paweł Leczkowski, Wiktor Ludwichowski, Emilia Łukasiuk

16 marca 2026

W związku z potrzebą utrzymania komunikacji z platformami wynoszącymi sondy badawcze na zadane wysokości zaproponowano stworzenie systemu predykcji lotu, pozwalającego na utrzymanie komunikacji z pojazdem mimo zakłóceń potencjalnie krytycznych. Algorytm oparty na zastosowaniu uczenia głębokiego wspierałby pojazd w przypadku awarii bądź zakłócenia. W systemach wykorzystujących komunikację jednostronną opartą na ciągłym pobieraniu danych dotyczących aktualnego stanu pojazdu przy jakiejkolwiek utracie ciągłości, tracona jest możliwość śledzenia aktualnego położenia pojazdu. W momencie gdy takie połączenie wymagane jest dla bezpieczeństwa misji i oceny dalszej możliwości kontynuacji jej prowadzenia, istotne jest, aby mimo przeszkód móc szacować aktualną pozycję do momentu odzyskania łączności. Zaproponowany algorytm byłby w stanie spełnić ten cel poprzez bieżącą analizę aktualnego toru lotu oraz przewidywać następne stany na podstawie danych teoretycznych dla konkretnej implementacji pojazdu.

1 Cel projektu

Głównym celem proponowanego projektu jest wytworzenie praktycznej implementacji wspierającej pojazdy suborbitalne poprzez metody bezpiecznego i skutecznego śledzenia tych obiektów. System ten byłby elementem krytycznym, znacznie przewyższającym możliwości systemów analitycznych. Uczenie maszynowe pozwala skrócić czas braku kontaktu, utrzymując w ten sposób dalsze działanie systemów awioniki oraz telemetrii. Kwestia łączności i sposobów bezpiecznego przesyłu oraz zestaw danych, które byłyby przesyłane nie są omawiane w tym opracowaniu, ale ich istotny wpływ uwzględniony będzie na etapie przygotowania danych do nauki modelu.

2 Teoretyczna przewidywalność toru lotu rakiet w modelu deterministycznym

Z punktu widzenia mechaniki klasycznej tor lotu rakiety jest jednoznacznie określony przez układ równań różniczkowych [1]. Zastosowanie opisu fizycznego zagadnienia zobowiązuje do określenia parametrów, takich jak funkcje zmiany masy w czasie, profilu ciągu czy gęstości atmosfery od wysokości. Istotne jest także ścisłe określenie stosowanego modelu oporu aerodynamicznego wraz z zadaniem warunków początkowych dla analizowanego scenariusza. Kwestie te są niezmienne względem sposobu ich rozwiązania, stanowią realne wyzwanie w kontekście modelowania i predykcji toru lotu pojazdu.

W sytuacji gdy rozwiązania pośrednie są możliwe do wyznaczenia, układ równań ruchu posiada jednoznaczne rozwiązanie. Oznacza to, że w sensie analitycznym trajektoria rakiety jest całkowicie przewidywalna. W warunkach rzeczywistych predykcja trajektorii jest jednak ograniczona przez szereg czynników:

- Nieliniowość i wrażliwość na warunki początkowe.
  Równania ruchu z oporem proporcjonalnym do kwadratu prędkości oraz zmienną masą stanowią układ nieliniowy. Niewielkie błędy w estymacji parametrów początkowych mogą prowadzić do istotnych odchyleń trajektorii w dalszej fazie lotu.

- Niepewność modelu atmosfery.
  Rzeczywista atmosfera wykazuje lokalne zaburzenia, turbulencje oraz zmienność w czasie. Modele wykładnicze stanowią przybliżenie średnie, lecz nie oddają krótkookresowych fluktuacji. Niemożliwe jest obecnie dokładne przewidzenie lokalnych ruchów atmosfery. [2]

- Błędy pomiarowe czujników.
  Akcelerometry, żyroskopy oraz systemy lokalizacyjne obarczone są szumem, dryftem oraz ograniczoną rozdzielczością. Propagacja tych błędów wpływa bezpośrednio na jakość rekonstrukcji stanu pojazdu.

- Działanie systemu sterowania.
  Rakieta nie porusza się po uprzednio wyznaczonej krzywej w sposób pasywny. Komputer pokładowy dokonuje ciągłych korekt wektora ciągu, reagując na lokalne zaburzenia. Oznacza to, że trajektoria jest wynikiem dynamicznego sprzężenia zwrotnego.

Z powyższych powodów należy stwierdzić, że idealne przewidzenie trajektorii nie jest możliwe w środowisku rzeczywistym, jednak możliwe jest osiągnięcie bardzo wysokiej dokładności estymacji przy zastosowaniu odpowiednich modeli i metod korekcji uwzględniających niepewność pomiarową i środowiskową.

Zastosowany opis ma na celu wykazanie potrzeby skorzystania ze sposobów odchodzących od czysto analitycznych. W dalszej części opracowania opisane zostanie wprowadzenie od strony ścisłej pod względem teoretycznym wraz z porównaniem problematyki numerycznej zagadnienia (Sekcja 7).

3 Opis praktycznych wyzwań związanych z odbiorem i obróbką sygnałów

W celu możliwie realistycznego odwzorowania warunków pomiarowych podczas lotu rakiety należy uwzględnić zarówno zakresy pomiarowe, jak i dokładność czujników zastosowanych w proponowanym modelu pojazdu. Wartości te znajdują się w Tabeli 1.

Dane generowane przez model trajektorii są najpierw dyskretyzowane zgodnie z częstotliwością próbkowania odpowiadającą rzeczywistym sensorom, a następnie obciążane syntetycznie generowanym szumem pomiarowym. Zakłada się, że błędy pomiarowe czujników mają charakter losowy i mogą być aproksymowane rozkładem normalnym o średniej równej zeru. W takim przypadku zaszumiony pomiar można zapisać jako wzór (1), gdzie paramter σ wynika z deklarowanej dokładności danego czujnika.

$$\tilde{x} = x + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \sigma^2), \tag{1}$$

Należy przy tym zachować spójność pomiędzy generowanym szumem pomiarowym a parametrami algorytmu Extended Kalman Filter, który wykorzystywany jest w dal-

szym etapie do estymacji stanu układu (Sekcja 7.1). W szczególności wariancja generowanego szumu powinna odpowiadać macierzy kowariancji pomiaru R używanej w filtrze EKF.

Tabela 1: Opis otrzymywanych danych w projekcie APEX wraz z zakresem działania oraz niepewnościami każdje z wielkości.

Wielkość	Czujnik	Dokładność	Zakres
Czas	Zegar czasu rzeczywistego STM32		
Wysokość	BME280 (na podstawie ciśnienia)	+-1hPa	Od 300 hPa do 1100 hPa
	GNSS MAX-M10S	1,5m	Altitude 80,000 m
Temperatura	BME280	+-1℃	Od -40℃ do 85 ℃
Ciśnienie	BME280	+- 1hPa	Od 300 hPa do 1100 hPa
Przyspieszenie całkowite (chwilowe)	LSM9DS1 IMU 9DOF	*	±2/±4/±8/±16 g
Prędkość całkowita (chwilowa)	GNSS MAX-M10S	0.05 m/s	0-500 m/s
Prędkość wertykalna (chwilowa)	GNSS MAX-M10S	0.05 m/s	0-500 m/s
Przyspieszenie wertykalne (chwilowe)	LSM9DS1 IMU 9DOF	0.061/0.122/0.244/0.732 [mg/LSB]	±2/±4/±8/±16 g
Długość geograficzna	GNSS MAX-M10S	1.5 m	Altitude 80,000 m
Szerokość geograficzna	GNSS MAX-M10S	1.5 m	Altitude 80,000 m
Prędkość kątowa przechylenia	LSM9DS1 IMU 9DOF	±245/±500/±2000 [dps]	8.75/17.50/70 [mdps/LSB]
Prędkość kątowa pochylenia	LSM9DS1 IMU 9DOF	±245/±500/±2000 [dps]	8.75/17.50/70 [mdps/LSB]
Prędkość kątowa odchylenia	LSM9DS1 IMU 9DOF	±245/±500/±2000 [dps]	8.75/17.50/70 [mdps/ LSB]

4 Akwizycja danych do nauki modelu

Tworzenie danych, na podstawie których przeprowadzana zostanie nauka algorytmu, bazować będzie na modelu fizycznym pojazdu symulowanym w oprogramowaniu OpenRocket. Założono, że wysoka dokładność stosowanego modelu bezpośrednio przełoży się na skuteczność końcowego systemu predykcyjnego [3]. Kluczowe dla wytworzenia rozwiązania działającego w sposób uogólniony będzie wygenerowanie różnorodnych scenariuszy lotu, uwzględniających zmienne warunki i zakłócenia. Pozyskiwane dane wejściowe obejmować będą położenie, prędkości oraz przyspieszenia chwilowe pojazdu. Dane te będą miały charakterystykę szeregów czasowych próbkowanych z określoną częstotliwością, co determinuje dobór algorytmów głębokiego uczenia.

Elementów skutkujących powstawaniem błędów krytycznych może być wiele, są to głównie nieliniowe zakłócenia sygnału, niestabilność i niepełność uzyskiwanych danych czy propagacja małych losowych odchyleń toru ze względu na zmienne warunki atmosferyczne. Dokładniejsza analiza tych zjawisk została przeprowadzona w Sekcji 2 i 3. Uwzględnienie ich ustalono za wystarczająco istotne, by chociaż częściowo odtworzyć ich efekty w danych, na których podstawie model będzie uczony.

Krok ten nie jest czysto teoretycznie wymagany do implementacji projektu, natomiast został uznany za istotny do zastosowania praktycznego modelu. Szumy i zakłócenia określono jako nieeliminowalne czynniki skutkujące osłabieniem jakości predykcji, tak więc model na poziomie treningu powinien również mieć z nimi pewną styczność. Decyzja ta powinna skutkować wyższym przystosowaniem do realnych warunków pracy algorytmu po zakończeniu jego nauki.

Przed nadaniem szumów dane uzyskane z symulacji lotów pojazdu poddane będą dyskretyzacji oraz dodatkowemu nadaniu błędów pseudolosowych w zakresie działania wykorzystanych czujników. Proponowane jest również podejście celowego wprowadzenia szczątkowych zestawów danych w niektórych scenariuszach, poszerzające zakres działania modelu na sytuacje gdy pewne czujniki są czasowo bądź całkiem niedostępne. Zabiegi te zastosowano w celu generalizacji podejścia algorytmu oraz do uzyskania narzędzia predykcji bez wymogu pełnego w dziedzinie czasu zestawu danych. Wszelkie zakresy nadawanych szumów i wprowadzenia błędów zostaną wykonane ściśle według kryteriów z Sekcji 3.

5 Proponowane metody uczenia maszynowego

Projekt zakłada wykorzystanie metody charakterystycznej dla modeli trenowanych na danych w dziedzinie czasu (Time Series Data). W trakcie analizy zagadnienia uwzględniono wiele możliwości doboru metod odpowiednich do jego opisu. Skupiono się głównie na podejściach bazujących na modelach klasy Rekurencyjnych Sieci Neuronowych (RNN) [4] lub Sieci Neuronowych Informowanych Fizyką (PINN) [5]. Poniżej opisano podstawy działania jednostek typu GRU oraz metodologię idącą za wykorzystaniem PINN.

5.1 Gated Recurrent Unit (GRU)

Klasycznym rozwiązaniem w sytuacjach wymagających użycia sieci typu RNN opisujących skutecznie systemy fizyczne zmienne w czasie jest wykorzystanie sieci LSTM. Są one znane z wysokiej wydajności i jakości otrzymywanych wyników lecz jest to kosztem znaczącego czasu oraz ilości danych do ich wytrenowania. Sieci GRU natomiast to metoda często wymieniana jako doskonała alternatywa dla LSTM, wyróżniająca się prostszą architekturą oraz wyższą szybkością działania i implementacji. Przy problemach predykcyjnych o umiarkowanej złożoności pozwala na osiągnięcie skuteczności zbliżonej do LSTM. Z tego powodu jest ona często preferowana w rozwiązaniach, w których dostępna pamięć i moc obliczeniowa są znacznie ograniczone, na przykład w systemach czasu rzeczywistego.

Zasadnicza różnica w strukturze komórki GRU w stosunku do LSTM polega na uproszczeniu mechanizmu pamięci. Zrezygnowano tutaj z oddzielnego stanu komórki pamięci na rzecz pojedynczego stanu ukrytego h_t, który pełni funkcję nośnika informacji. Co więcej, GRU redukuje liczbę bramek, łącząc klasyczną bramkę zapominania (forget gate) oraz bramkę wejściową (input gate) w pojedynczą bramkę aktualizacji (update gate) [6], która pozwala modelowi określić ile informacji z przeszłości (z poprzednich kroków czasowych) powinno zostać przekazane do przyszłości. Im wyższa wartość w tej bramce, tym więcej informacji jest zachowywanych w stanie obecnym. Jest to szczególnie przydatne, ponieważ dzięki temu model ma możliwość zachowania istotnych informacji z poprzednich kroków, co zmniejsza ryzyko wystąpienia problemu zanikających gradientów. Dodatkowo struktura wykorzystuje bramkę resetowania (reset gate), która decyduje o tym, ile informacji z przeszłości można pominąć. Im niższa wartość bramki, tym więcej danych zostaje zignorowanych. W ramach bramki resetowania wprowadza się również current memory gate, która dodaje nieliniową charakterystykę do danych wejściowych oraz normalizuje je wokół zera. Dzięki temu wpływ wcześniejszych informacji na stan obecny jest kontrolowany i redukowany, co pomaga w lepszym przekazywaniu istotnych danych w czasie. [7]

Praktyczne zastosowanie sieci GRU w przypadkach zbliżonych do opisanego przez nas problemu przewidywania trajektorii zostało szczegółowo przeanalizowane w artykule [6].

5.2 Modele bazujące na PINN (Physics-Informed Neural Networks)

Sieci PINN są trenowane do rozwiązywania problemów z zachowaniem określonych praw fizyki, opisywanych za pomocą ogólnych, nieliniowych równań różniczkowych cząstkowych [8]. Strukturę sieci PINN można określić jako modularną, składającą się z trzech głównych komponentów: aproksymatora (sieci neuronowej przybliżającej szukaną funkcję), modułu wprowadzającego wiedzę fizyczną (definiującego postać funkcji straty na podstawie równań) oraz optymalizatora służącego do minimalizacji tej straty. Architektura sieci neuronowej determinuje, jak dokładnie może ona aproksymować funkcję docelową. Sposób iteracyjnej poprawy aproksymatora zdefiniowany jest przez funkcję straty oraz liczbę punktów kolokacyjnych (zbioru danych wejściowych), w których ewaluowane są równania. Odchylenie modelu od rzeczywistego rozwiązania mierzone jest za pomocą błędu uogólnienia. Z kolei skuteczność procesu minimalizacji zależy od algorytmu optymalizacji, a ewentualne niedokładności z nim związane określa się mianem błędu optymalizacji [9].

Co istotne, sieci PINN nie wymagają do treningu klasycznych, etykietowanych danych (takich jak wyniki wcześniejszych symulacji czy eksperymentów), dzięki czemu proces ich uczenia może być traktowany jako nienadzorowany (lub samonadzorowany). Metoda ta znajduje rozwiązania równań różniczkowych cząstkowych poprzez przekształcenie tego zagadnienia w problem optymalizacji (minimalizacji) funkcji straty [9].

W zaawansowanych systemach predykcyjnych metody typu PINN często stosowane są w połączeniu z klasycznymi sieciami rekurencyjnymi, takimi jak LSTM. W artykule [10] autor przewiduje trajektorię lotu wykorzystując sieć LSTM wzbogaconą o dodatkową warstwę PINN, co gwarantuje, że wyniki generowane przez model pozostają w zgodzie z prawami fizyki (np. kinematyki lotu).

W literaturze wyróżnia się różne warianty i sformułowania sieci PINN, w tym:

- PINN w postaci słabej (weak form, np. hp-VPINNs),
- PINN w postaci energetycznej (energy form, np. DEM: Deep Energy Method),
- PINN w postaci odwrotnej (inverse form, np. BINN: Boundary Element Method).

Mimo, że podejścia te definiują nieliniowe równania różniczkowe cząstkowe w różnych formach i są matematycznie równoważne, różnią się one znacząco pod względem charakterystyki i złożoności obliczeniowej [11].

5.3 Argumentacja wybranej metodologii

Ostatecznie wybrano podejście skupiające wykorzystanie sieci typu Gated Recurrent Unit (GRU), nadając dodatkowe ograniczenia modelu według metodologii PINN. Wśród sposóbów ufizyczniania algorytmu jest wiele sprawdzonych metod, natomiast tą umożliwiającą jak najlepsze oszacowanie trajektorii jest tzw. metodologia Inverse PINN (Sekcja 5.2), zostawiająca modelowi uczenia głębokiego całkowitą swobodę w wyprowadzeniu wyniku. Ingerencja następuje dopiero gdy sieć wytworzy proponowany wynik, który następnie weryfikowany jest z otrzymywanymi wynikami. W zaproponowanym podejściu nie zastosowano klasycznego ujęcia twardych więzów, polegającego na czystym sprawdzeniu wartości z możliwie jak największą dokładnością i odrzuceniu wyniku przy jakimkolwiek odstępstwie. Podejście więzów miękkich pozwala na wystąpienie pewnego błędu w wyniku, we wcześniej określonym zakresie, tak by chwilowy błąd, który mógłby wystąpić ze względu na błędy przesyłu sygnału, nie był traktowany jako element odrzucający propozycję sieci GRU. Główną wadą tego podejścia jest ryzyko uzyskania modelu o niższej dokładności, umożliwia to jednak zachowanie danych obarczonych pewnym nieznacznym błędem, co zmniejsza prawdopodobieństwo zagłodzenia algorytmu [12].

6 Metody oceny jakości modelu i potrzeby reiteracji

6.1 Definicja błędu predykcji

Niech $\mathbf{x}(t)$ oznacza rzeczywisty wektor stanu rakiety, natomiast $\hat{\mathbf{x}}(t)$ jego estymację uzyskaną przez wybrany model. Błąd predykcji $\mathbf{e}(t)$ zdefiniowany jest wzorem (2). Dla potrzeb analizy pozycji w przestrzeni trójwymiarowej stosuje się normę euklidesową błędu położenia określoną jako wzór (3).

$$\mathbf{e}(t) = \mathbf{x}(t) - \hat{\mathbf{x}(t)} \tag{2}$$

$$\mathbf{e_p}(t) = \|\mathbf{x}(t) - \hat{\mathbf{x}}(t)\|_2 \tag{3}$$

W analizie prędkości oraz przyspieszenia analogicznie definiuje się błąd w przestrzeni odpowiednich składowych. Do oceny jakości modelu proponuje się zastosowanie następujących miar - Średni błąd bezwzględny (MAE) (4), Pierwiastek z sumy kwadratów odległości (RMSE) (5) oraz Maksymalny błąd chwilowy (MTIE) (6). Warto również wspomnieć o często stosowyanym błędzie horyzontu predykcji, czyli średnim błędzie po czasie ΔT od momentu utraty łączności.

$$MAE = \frac{1}{N}\sum_{i=1}^{N} \|\mathbf{e}(t_i)\| \tag{4}$$

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N} \|\mathbf{e}(t_i)\|^2} \tag{5}$$

$$e_{max} = \max_{t\in[t_0,t_f]} \|\mathbf{e}(t)\| \tag{6}$$

W kontekście bezpieczeństwa misji kluczowym parametrem jest maksymalny dopuszczalny błąd pozycji e_{crit}, po przekroczeniu którego estymacja przestaje być operacyjnie użyteczna

6.2 Kryteria reiteracji modelu oraz jego walidacji

Względem miar oraz błędów określonych w poprzedniej Sekcji kluczowe jest określenie kryteriów opisujących przypadki sugerujące potrzebę reiteracji. Przyjęto taką potrzebę, w sytuacji gdy wartości $RMSE$ lub e_{max} przekroczą odpowiadającą im określoną wartość krytyczną $RMSE_{crit}$ lub e_{crit}. Do sytuacji wskazujących potrzebę powtórnej próby zaliczono również momenty gdy w trakcie nauki obserwowany jest drift estymacji albo zmienione zostały parametry fizyczne pojazdu. Żaden z tych przypadków po zaobserwowaniu nie powinien dopuszczać dalszych możliwości w utrzymaniu dotychczasowego stanu.

Walidacja modelu natomiast możliwa jest na podstawie poprawnego podziału danych na zbiory treningowe, walidacyjne i testowe oraz poźniejszego przeprowadzenia testów w scenariuszach nominalnych i zaburzonych, a także finalną analizę stabilności predykcji zarówno krótko jak i długoterminowej.

7 Schemat implementacji algorytmu predykcji

Problem opisu systemu dynamicznego i optymalna predykcja dalszego toru lotu ciała rozwiązane będą przez próbę wprowadzenia modelu polegającego na wykorzystaniu rekurencyjnej sieci neuronowej GRU wraz z metodyką PINN (Sekcja 5).

Uczenie polegałoby na rozłożeniu danych wejściowych na te wymagane do szkolenia algorytmu GRU oraz części potrzebnej wyłącznie do algorytmu klasycznego. Podział problemu uzasadniono zminimalizowaniem możliwości wahań proponowanych wyników, w sytuacji gdy problem jest rozwiązywalny w znacznej jego części numerycznie.

W zależności od ostatecznego wyboru metodologii rozwiązania problemu fizycznego, czy to przez dopasowanie sił bądź przyspieszeń w spojrzeniu Newtonowskim czy to przez określenie układu przez Lagranżjan oraz uogólnione siły dysypacyjne (z dodatkowym podziałem na określalne analitycznie oraz nieokreślalne analityczne), problem redukuje się do dwóch podsegmentów, gdzie pierwszy byłby problemem czysto numerycznym, drugi zaś dotykałby tematyki uczenia głębokiego.

Głównym elementem tego opracowania jest opis schematu działania w przypadku modelu uczenia głębokiego (GRU), który w dalszej części opisywany będzie nazwą Segment S. Drugi element przetwarzania (numeryczny) będzie wyrażany przez nazwę Segment B. Integracja działania i weryfikacja zgodności wyników pod względem więzów fizycznych jest funkcją osobnej jednostki nazwanej Segmentem I. Schemat przepływu informacji wraz z oznaczeniem podziału umieszczono na Rysunku 1.

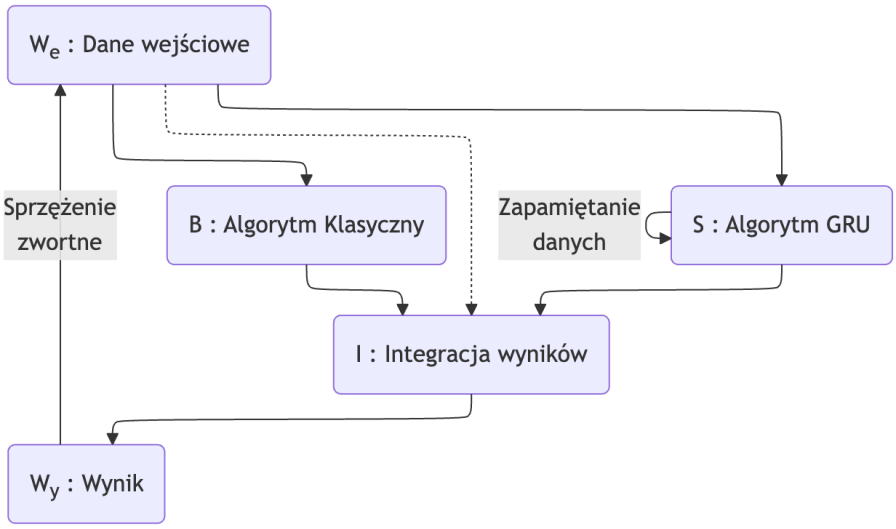

Rysunek 1: Schemat przepływu informacji wewnątrz modelu

7.1 Segment W_e - redukcja zakłóceń i podział danych

Pomiary uzyskiwane z czujników pokładowych, takich jak akcelerometry, żyroskopy oraz systemy lokalizacyjne (Sekcja 3.), są obarczone szumem pomiarowym oraz błędami systematycznymi. Zakłócenia te powodują narastanie błędu estymacji stanu pojazdu w czasie i mogą prowadzić do znacznych odchyleń w rekonstrukcji trajektorii lotu. W celu ograniczenia wpływu tych błędów stosuje się metody estymacji stanu, w szczególności filtr Kalmana oraz jego rozszerzoną wersję - Extended Kalman Filter (EKF).

Extended Kalman Filter stanowi rozszerzenie klasycznego filtra Kalmana dla układów nieliniowych. W ogólnym przypadku dynamika układu opisywana jest równaniem przejścia stanu (7), natomiast model pomiaru ma postać (8),gdzie x_k oznacza wektor stanu układu, z_k wektor pomiarów z czujników, natomiast w_k oraz v_k reprezentują odpowiednio szum procesu oraz szum pomiarowy.

$$x_k = f(x_{k-1}, u_k) + w_k \tag{7}$$

$$z_k = h(x_k) + v_k \tag{8}$$

Ponieważ funkcje $f(\cdot)$ oraz $h(\cdot)$ mają charakter nieliniowy, w algorytmie EKF są one lokalnie linearyzowane poprzez rozwinięcie w szereg Taylora pierwszego rzędu wokół aktualnej estymacji stanu. W wyniku tego wyznaczane są macierze Jacobiego (9), które opisują lokalnie liniową dynamikę systemu [13].

$$F_k = \frac{\partial f}{\partial x}, \qquad H_k = \frac{\partial h}{\partial x} \tag{9}$$

Algorytm EKF działa iteracyjnie w dwóch etapach: predykcji oraz korekty. W kroku predykcji wyznaczany jest przewidywany stan układu (10) oraz macierz kowariancji błędu (11).

$$\hat{x}_{k|k-1} = f(\hat{x}_{k-1|k-1}, u_k) \tag{10}$$

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^T + Q. \tag{11}$$

Następnie w kroku korekty estymacja jest aktualizowana na podstawie nowych pomiarów. W tym celu obliczane jest wzmocnienie Kalmana (12), a stan układu aktualizowany jest zgodnie z zależnością (13).

$$K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R)^{-1}, \tag{12}$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k(z_k - h(\hat{x}_{k|k-1})). \tag{13}$$

Zastosowanie filtra EKF umożliwia fuzję danych pochodzących z wielu czujników oraz znaczną redukcję wpływu szumu pomiarowego. Dzięki temu możliwa jest stabilna estymacja wektora stanu pojazdu obejmującego jego położenie, prędkość oraz orientację przestrzenną, co jest kluczowe w systemach predykcji trajektorii lotu [13].

Dane otrzymywane z czujników są wstępnie przetwarzane oraz dzielone na zestawy przeznaczone do poszczególnych segmentów systemu. Część z nich jest wykorzystywana przez komponent numeryczny modelu fizycznego, natomiast sekwencje stanów w dziedzinie czasu stanowią wejście dla modelu uczenia maszynowego.

7.2 Segment B - wykorzystanie metod numerycznych

Jak wykazano w Sekcji 2, ze względu na nieliniowość układu równań oraz zmienność parametrów w czasie uzyskanie analitycznego rozwiązania dla pełnego modelu jest w praktyce niemożliwe. W związku z tym konieczne jest zastosowanie metod całkowania numerycznego równań różniczkowych zwyczajnych (ODE), które pozwalają na przybliżone wyznaczanie trajektorii układu w kolejnych krokach czasowych.

Najprostszą i jednocześnie najbardziej intuicyjną metodą całkowania numerycznego jest metoda Eulera. Polega ona na wyznaczeniu kolejnego stanu układu na podstawie wartości funkcji w poprzednim kroku czasowym oraz przyrostu wynikającego z równania różniczkowego. Metoda Eulera charakteryzuje się niską złożonością obliczeniową, lecz jej główną wadą jest większy błąd numeryczny, który narasta w miarę kontynuacji działania. Z tego powodu w praktycznych zastosowaniach stosowana jest głównie w prostych symulacjach lub w celach demonstracyjnych.

Znacznie większą dokładność zapewniają metody z rodziny Rungego-Kutty (RK)[14], w których przybliżenie nowego stanu układu uwzględnia wartość funkcji w kilku punktach wewnętrznych kroku czasowego. W szczególności często stosowana jest metoda czwartego rzędu (RK4), która stanowi kompromis pomiędzy dokładnością obliczeń a złożonością obliczeniową. RK4 jest szeroko stosowana w symulacjach, gdzie wymagana jest duża precyzja przy umiarkowanych kosztach obliczeniowych.

W kontekście symulacji trajektorii lotu istotna jest stabilność symulacji podczas długotrwałej integracji, dlatego w analizie rozważa się również zastosowanie metod symplektycznych, takich jak algorytm skokowy (Leapfrog) [15]. Metody te wskazują wysoką stabilność numeryczną w długoterminowych symulacjach. Ich istotą jest ograniczenie przyrostu błędów numerycznych poprzez zachowanie energii w symulowanym układzie, co jest szczególnie istotne w symulacjach balistycznych, gdzie niewielkie błędy mogą prowadzić do znacznych odchyleń w dalszej predykcji.

W praktycznej implementacji systemu przewidywania trajektorii metoda całkowania numerycznego, a dokładniej wcześniej opisana metoda RK4, będzie pełniła rolę deterministycznego komponentu modelu, generując bazową część predykcji trajektorii na podstawie równań fizycznych.

7.3 Segment S - Architektura sieci

7.3.1 Opis wykorzystania sieci GRU

Sieci GRU przetwarzają sekwencyjne dane wejściowe w sposób iteracyjny. W każdym kroku czasowym sieć otrzymuje serie danych wejściowych pokrywających przedział czasu n, którego dokładna wartość zostanie podana w późniejszej fazie projektu. Komórki GRU są w stanie śledzić dynamikę pojazdu suborbitalnego za pomocą stanu ukrytego oznaczanego jako h_{t-1}, który zawiera informacje z wcześniejszych punktów danych (ang. data points) w sekwencji i w kolejnym kroku jest łączony z nowym fragmentem danych wejściowych. Ten cykliczny proces zapewnia nieustanną aktualizację i integrację informacji w trakcie przetwarzania sekwencji, co pozwala na przewidywanie trajektorii lotu pojazdu w następnych m sekundach, gdzie wartość m zostanie dokładnie określona wraz z dalszym rozwojem projektu.

Podejście to umożliwia szybką predykcję danych w ograniczonym przedziale czasu bez obciążania pamięci modelu. Należy pamiętać, iż dobranie zbyt długiego przedziału czasowego m może skutkować wystąpieniem problemu zanikających bądź eksplodujących gradientów, co negatywnie wpływa na skuteczność działania sieci GRU. [16]

Określenie wymiaru wektora h_{t-1} jest kluczowe do efektywnego działania modelu. Większy wymiar h_{t-1} pozwala modelowi na wychwytywanie bardziej złożonych zależności, natomiast zwiększa ono też złożoność obliczeniową modelu. Ważnym aspektem jest także liczba warstw modelu. Obie wartości zostaną najprawdopodobniej wyznaczone eksperymentalnie.

7.3.2 Schemat działania sieci GRU

Na początku, na podstawie stanu ukrytego h_{t-1} przekazanego z poprzedniej komórki oraz bieżącego wejścia x_t, obliczane są wartości bramek aktualizacji z (14) i resetowania r (15) w chwili czasu t, gdzie W_z i W_r oznaczają macierze wag odpowiednio dla bramki aktualizacji i resetowania, natomiast σ oznacza funkcję sigmoidalną, która ogranicza wartość bramki do przedziału od 0 do 1.

$$z_t = \sigma\left(W_z \cdot [h_{t-1}, x_t]\right) \tag{14}$$

$$r_t = \sigma\left(W_r \cdot [h_{t-1}, x_t]\right) \tag{15}$$

Po wyznaczeniu wartości bramki następuje obliczenie nowego stanu ukrytego h'_t na podstawie wyrażenia (16), gdzie bramka resetowania oblicza $r_t * h_{t-1}$ i łączy wynik operacji z wejściem x_t, natomiast funkcja *tanh* ogranicza dane do zakresu od -1 do 1.

$$h'_t = tanh(W \cdot [r_t * h_{t-1}, x_t]) \tag{16}$$

Następnie obliczana jest wartość pamięci aktualizowanej zgodnie ze wzorami (17) i (18), gdzie h_t to ostateczny stan ukryty, z_t to wartość bramki aktualizacji w ostatnim kroku, która selektywnie przechowuje nowy stan ukryty h'_t, a $(1-z_t)$ pozwala zapomnieć część nieistotnych informacji z poprzedniego stanu ukrytego h_{t-1}. W rezultacie można uzyskać wyjście y_t sieci GRU. [17]

$$h_t = (1-z_t) * h_{t-1} + z_t * h'_t \tag{17}$$

$$y_t = \sigma(W_0{}^* h_t) \tag{18}$$

7.4 Segment I - Integracja wyników oraz weryfikacja

Przez podział zagadnienia predykcji na część numeryczną oraz modelu uczenia głębokiego, niezbędne było stworzenie systemu integrującego te dwie części. Takowy system opisuje zarówno proces uczenia jak i rzeczywiste przetwarzanie sieci.

7.4.1 Przetwarzanie sieci

W trybie operacyjnym Segment I odpowiada za fuzję danych w czasie rzeczywistym. Ostateczny zintegrowany stan można określić jako sumę stanów pozyskanych z rozwiązania klasycznego i opartego na uczeniu głębokim (19).

$$\ddot{x}_I = \ddot{x}_B + \ddot{x}_S \tag{19}$$

7.4.2 Trenowanie zintegrowanego rozwiązania

W proponowanej architekturze proces predykcji przez model nie polega na estymacji pełnej trajektori lotu, lecz na modelowaniu dynamiki niepewnej. Zgodnie z założeniami podziału, estymowany wektor stanu układu dzieli się na komponent bazowy wyznaczany na podstawie segmentu B, oraz komponent resztkowy będący wynikiem segmentu S. Aby proces optymalizacji wag sieci odzwierciedlał rzeczywiste błędy predykcji, wybrana funkcja straty ocenia zintegrowany wynik, a nie wyłącznie predykcje sieci GRU. Dla tej metodologii proponowana funkcja straty przyjmuje następującą postać (20), gdzie N oznacza liczbę analizowanych kroków, x_B oraz x_S przedstawiają wektor stanu wyznaczony przez odpowiednie segmenty, x_{true} przedstawia wartość oczekiwaną, L_{PINN} jest błędem niespełnienia miękkich więzów fizycznych, λ_{PINN} to dynamicznie skalowana waga.

$$L_{Total} = \frac{1}{N}\sum_{i=1}^{N} ||(x_B(t_i) + x_S(t_i)) - x_{true}(t_i)||^2 + \lambda_{PINN} L_{PINN} \tag{20}$$

Aby zapewnić spójność wyników uczenia z prawami fizyki, została zaimplementowana warstwa IPINN. W celu uniknięcia problemu zagłodzenia algorytmu przy danych zawierających szumy, zastosowano podejście więzów miękkich. Podejście to pozwala na wystąpienie kontrolowanego o określonym zakresie.

7.5 Wybór metodologii opisu zagadnienia fizycznego

Niezależnie od doboru alogrytmu odpowiedzialnego za przewidywanie wartości silnie losowych (segment S), wymagany jest wybór metodologii implementacji problemu fizycznego, którego opis może być wykonany na wiele sposobów. Głównymi metodologiami w przypadku problemów głównie dynamicznych są sformułowanie Newtonowskie i Lagranżowskie. W tym przypadku czysto analitycznie oba sformułowania prowadzą do identycznych konkluzji, natomiast, w przypadku gdy znaczna część opisanego problemu redukuje się do zagadnienia numerycznego, wyjątkowo istotny jest dobór podejścia upraszczajacy obliczenia numeryczne razem z utrzymaniem wystarczającej dokładności wyników.

Wprowadzenie teoretyczne do zagadnienia według każdej z wcześniej wymienionych metodologii przeprowadzono w dalszej części opracowania. Ma ono na celu przybliżenie głównych zalet oraz wyzwań związanych z ich doborem. Na ten moment nie podjęto dalszych kroków, takich jak wybór czy implementacja odpowiedniego z nich dla analizowanego zagadnienia.

7.5.1 Sformułowanie Newtonowskie (siłowe)

Klasycznym rozwiązaniem problemu byłoby skorzystanie z opisu dynamiki według Newtona. Tu analizie poddawane są siły działające na pojazd. Ze względu na wspólny czynnik wielu wyrazów, jakim jest masa pojazdu zależna od czasu ($m(t)$), równanie uproszczono do formy opisanej wzorem (10). Wyrażenie to jest fragmentem całościowego spojrzenia (12), odnoszącego się wyłącznie do fragmentu deterministycznego badanego zagadnienia. Zastosowano tu oznacznie $\boldsymbol{\omega}$ jako prędkości kątowej Ziemi, a $T(t)$ jako siły ciągu silnika, opisując w ten sposób czynniki odpowiedzialne za ciąg (co jest zależne od samego systemu kontroli pojazdu) oraz sił charakterystycznych w opisie ciała wewnątrz układu nieinercjalnego (Ziemia).

Wyrażenie (11) określa łączny wpływ wartości sił odpowiedzialnych za stratę energetyczną, klasycznie opisywaną metodologią fizyki statystycznej. Jak wcześniej opisano, ten element może wpływać na największe propagujące się zmiany w trajektorii, tworząc błędy, które klasycznie byłyby możliwe do predykcji wyłącznie z ograniczoną dokładnością. Wewnętrznie model GRU nie rozgranicza wpływów pojedynczych sił (tj. D czy L) na rzecz odnalezienia rozwiązania ogólnego dla każdego z przypadków, pozwalając na prostą weryfikację wyłącznie jednej zmiennej $\ddot{x}_S$ - przyspieszenia wynikającego z wcześniej wspomnianych sił dyssypacyjnych.

$$\ddot{x}_B = \frac{T(t)}{m(t)} + g(R_0 + x) - 2(\boldsymbol{\omega} + \dot{x}) - \boldsymbol{\omega} \times (\boldsymbol{\omega} \times (R_0 + x)) \tag{21}$$

$$\ddot{x}_S = \frac{1}{m(t)} \cdot (D(\dot{x}, x) + L(\dot{x}, x)) \tag{22}$$

$$\ddot{x}_I \stackrel{?}{=} \ddot{x}_B + \ddot{x}_S \tag{23}$$

Wyzwaniem numerycznym przy opisie problemu w sformułowaniu Newtonowskim jest głównie praca na wielkościach wektorowych. Mając na względzie, że znaczna część wielkości jest wielkościami wektorowymi (m. in. x, T, $\boldsymbol{\omega}$), działania pomiędzy nimi również wymagają utrzymania odpowiedniej metodologii. Wynik modelu (tj. $\ddot{x}_S$) ze względu na naturę wektorową mógłby być weryfikowany w sposób bardziej rygorystyczny, dając autorom możliwość na dokładniejszą kontrolę każdej z składowych. Podejście to natomiast niesie za sobą również skutki negatywne, bowiem znaczna ingerencja w działanie modelu cząstkowe modelu mogłaby wpłynąć na niższą generalizację otrzymywanych wyników.

Warto wspomnieć także o praktyczności otrzymywanego wyniku. Wielkość, jaką jest przyspieszenie, pozwala na znacznie prostszą interpretację i weryfikację. Jest ona po weryfikacji (12) gotowa do wykorzystania - nie wymaga dodatkowych przekształceń. Otrzymanie położenia z postaci (12), śledząc każdy kolejny krok, jest znacząco prostsze względem wyników otrzymywanych poprzez wykorzystanie sformułowania Lagranżowskiego (8.5.2).

7.5.2 Sformułowanie Lagranżowskie (energetyczne)

W przypadku opisu zagadnienia w formalizmie Lagranżowskim (13), odchodzi się od stosowania wielkośći wektorowych na rzecz skalarów. Głównym wyzwaniem okazuje się numeryczna implementacja różniczkowania, która jest kluczem do określenia wartości składowych (13), a następnie weryfikacji głównego warunku akceptacji wyniku (14). W równaniach opisanych poniżej stosuje się klasyczne równania Lagranża drugiego rodzaju w przypadku układu współrzędnych naturalnych opisanych wektorem odległości r oraz uzględnienia uogólnionych sił dysypacyjnych (Q_T oraz Q_S). Standardowy parametr grawiatacyjny Ziemi oznaczono zaś jako μ.

$$\begin{cases} Q_B = \frac{d}{dt}(\frac{\partial \mathscr{L}}{\partial \dot{r}}) - \frac{\partial \mathscr{L}}{\partial r} - Q_T \\ \mathscr{L}(r,\dot{r},t) = \frac{1}{2}m(t)||\dot{r} + \omega \times r||^2 + \frac{\mu m(t)}{||r||} \\ Q_T = T(t) \end{cases} \tag{24}$$

$$Q_B - Q_S \stackrel{?}{=} 0 \tag{25}$$

Kwestia wielkości dopasowanych przez model analogicznie jak w Sekcji 7.5.1, odnosi się do wielkości fizycznych opisywanych w sposób statystyczny, łącząc różne wielkości w sposób chaotyczny odpowiedzialne za przesunięcia horyzontalne. Pozwala to na pominięcie opisu wszelkich podproblemów, za które odpowiedzialny będzie model segmentu S i redukcję do weryfikacji wartości Q_s względem pozostałych czynników (14).

Istotnym elementem w przypadku zastosowania wcześniej opisanego formalizmu jest otrzymanie wyniku w postaci nieintuicyjnej dla użytkownika. Naturalne jest zastosowanie przejścia ponownie do opisu za pomocą przyspieszeń i położeń. Jest to znaczący krok, który należy uwzględnić przed finalną prezentacją wyników, natomiast względem samego działania algorytmu jest on całkowicie zbędny.

7.6 Segment W_y - Zastosowanie wyniku systemu predykcji

Bezpośrednio zintegrowany przez segment I wynik, opisujący stan ciała w danym momencie, możliwy jest do przekazania poza system będący tematem tego opracowania. Dane te wykorzystywane są jednak do dalszego funkcjonowania algorytmu przez sprzężenie zwrotne. Zabieg ten zastosowano, by w sytuacjach odcięcia od nadchodzących danych z czujników przepływ danych nie ustawał. Rozwiązanie to ma być na wyłącznie tymczasowym etapem w działaniu, lecz niezbędnym do spełnienia praktycznych wymogów opisanych w początkowych częściach opracowania.

Literatura

[1] Luís MBC Campos and Paulo JS Gil. On four new methods of analytical calculation of rocket trajectories. Aerospace, 5(3):88, 2018.

[2] Julia Slingo and Tim Palmer. Uncertainty in weather and climate prediction. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 369(1956):4751–4767, 12 2011.

[3] C. Huyen. Designing Machine Learning Systems: An Iterative Process for Production-ready Applications. O'Reilly Media, Incorporated, 2022.

[4] Alicia Roux, Sébastien Changey, Jonathan Weber, and Jean-Philippe Lauffenburger. LSTM-Based Projectile Trajectory Estimation in a GNSS-Denied Environment. Sensors, 23(6):3025, 2023.

[5] Bingsan Yang, Tao Wang, Bin Li, Qianqian Zhan, and Fei Wang. Real-Time Trajectory Prediction for Rocket-Powered Vehicle Based on Domain Knowledge and Deep Neural Networks. Aerospace, 12(9):760, 2025.

[6] Ping Han, Wenqing Wang, Qingyan Shi, and Jun Yang. Real-time short- term trajectory prediction based on gru neural network. In 2019 IEEE/AIAA 38th Digital Avionics Systems Conference (DASC), pages 1–8, 2019.

[7] Francesca Lazzeri. Machine Learning for Time Series Forecasting with Python. John Wiley & Sons, 2021.

[8] M. Raissi, P. Perdikaris, and G.E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. Journal of Computational Physics, 378:686–707, 2019.

[9] Salvatore Cuomo, Vincenzo Schiano Di Cola, Fabio Giampaolo, Gianluigi Rozza, Maziar Raissi, and Francesco Piccialli. Scientific Machine Learning Through Physics–Informed Neural Networks: Where we are and What's Next. Journal of Scientific Computing, 92(3):88, 2022.

[10] Murari Prasad Samal. Machine Learning-Based Autonomous Flight Vehicle Trajectory Rectification System: A Comprehensive Framework for Real-Time Path Correction, February 2026. Preprint. Simulation-based research study, Silicon University, India.

[11] Yizheng Wang, Jia Sun, Jinshuai Bai, Cosmin Anitescu, Mohammad Sadegh Eshaghi, Xiaoying Zhuang, Timon Rabczuk, and Yinghua Liu. Kolmogorov–arnold-informed neural network: A physics-informed deep learning framework for solving forward and inverse problems based on kolmogorov–arnold networks. Computer Methods in Applied Mechanics and Engineering, 433:117518, 2025.

[12] Lena Podina, Brydon Eastman, and Mohammad Kohandel. A pinn approach to symbolic differential operator discovery with sparse data. arXiv, 2022.

[13] Gyubeom Edward Im. Notes on kalman filter (kf, ekf, eskf, iekf, ieskf), June 2024. Technical notes.

[14] Z.A. Anastassi and T.E. Simos. An optimized runge–kutta method for the solution of orbital problems. Journal of Computational and Applied Mathematics, 175(1):1–9, 2005. Selected Papers of the International Conference on Computational Methods in Sciences and Engineering.

[15] A. ISERLES. Generalized leapfrog methods. IMA Journal of Numerical Analysis, 6(4):381–392, 10 1986.

[16] Lahouari Ghouti Kahled Gabr Abdulrahman S. Al-Batati Anis Koubaa Omer Nacar, Mohamed Abdelkader. Vector: Velocity-enhanced gru neural network for real-time 3d uav trajectory prediction. arXiv, pages 7–9, 2024.

[17] Lan Wang Zexuan Chen. Aircraft trajectory prediction model based on improved gru structure. 2023.

[18] Ahmed E. Mahdi, Ahmed Azouz, Ahmed E. Abdalla, and Ashraf Abosekeen. A Machine Learning Approach for an Improved Inertial Navigation System Solution. Sensors, 22(4):1687, 2022.

[19] Amir Hossein Baradaran. Advanced prediction of hypersonic missile trajectories with cnn-lstm-gru architectures, 03 2025.

[20] Furong Liu, Lina Lu, Zhiheng Zhang, Yu Xie, and Jing Chen. Intelligent trajectory prediction algorithm for hypersonic vehicle based on sparse associative structure model. Drones, 8:505, 09 2024.

[21] Michael A. Nielsen. Neural networks and deep learning, 2018.

(wersja γ - 16.03.26)